

# **Antecipação e adaptação: como incorporar o dinamismo do mundo financeiro**

Igor Nascimento

Laboratório de Aprendizado de Máquina em Finanças e Organizações - LAMFO

28/02/2018

# Sumário

## Introdução

## Stochastic Dynamic Programming

## Amostragem aleatória (Intuitivo)

- Monte Carlo

- Bootstrap

## Modelos Dinâmicos

- Monte Carlo

## Filtro de Partículas

- Filtro Bootstrap

## Stochastic Volatility Models

O investidor (banco, pessoa física, fundo de investimento, fundo de pensão) possui um capital e deseja utilizá-lo para atingir um objetivo:

- ▶ Rendimento superior a taxa de captação
- ▶ Segurança financeira
- ▶ Lucro ao investidor
- ▶ Aposentadoria

- ▶ Ações (PETR3, VALE3, IBOVESPA)

## Ativos

- ▶ Ações (PETR3, VALE3, IBOVESPA)
- ▶ Títulos de dívida pública (NTN-B, LTN)

## Ativos

- ▶ Ações (PETR3, VALE3, IBOVESPA)
- ▶ Títulos de dívida pública (NTN-B, LTN)
- ▶ Empresa de terceiros (Debêntures)

## Ativos

- ▶ Ações (PETR3, VALE3, IBOVESPA)
- ▶ Títulos de dívida pública (NTN-B, LTN)
- ▶ Empresa de terceiros (Debêntures)
- ▶ Empresas própria (Empresário)

## Ativos

- ▶ Ações (PETR3, VALE3, IBOVESPA)
- ▶ Títulos de dívida pública (NTN-B, LTN)
- ▶ Empresa de terceiros (Debêntures)
- ▶ Empresas própria (Empresário)
- ▶ Outros (criptomoeda, Avestrus Master, Hinode)

Alocação de ativos ou portfólio é **escolher** um ou mais ativos.



# Alocação

- ▶ Retorno: qual o valor esperado ao final do investimento
- ▶ Risco: quais são os valores possíveis para o retorno

O trabalho seminal de Markowitz (1952) sobre alocação de portfólio e fronteira eficiente.

## Markowitz (1952)

- ▶ ativos:

$$r_1, r_2, \dots, r_N$$

- ▶ retorno:

$$E(r_1) = \mu_1, E(r_2) = \mu_2, \dots, E(r_N) = \mu_N$$

- ▶ variância:

$$V(r_1) = \sigma_1^2, V(r_2) = \sigma_2^2, \dots, V(r_N) = \sigma_N^2$$

- ▶ covariância (correlação):

$$COR(r_i, r_j) = \rho_{ij}$$

## Alocação


Determinar a locação, isto é, o percentual  $p_1, p_2, \dots, p_N$  que cada ativo representa da carteira:

$$E_{portfolio} = E(\mathbf{P}) = \sum_{i=1}^N p_i \times \mu_i \quad (1)$$

$$V_{portfolio} = V(\mathbf{P}) = \sum_{i=1}^N \sum_{j=1}^N p_i p_j \times \sigma_i \sigma_j \times \rho_{ij} \quad (2)$$

## Fronteira Eficiente


*"Optimal weight of each asset, such that the overall portfolio provides the best return for a fixed level of risk, or conversely, the smallest risk for a given overall return?" Laloux et al. (1999)*





## Minicaseo

- ▶ IFN: índice setor financeiro
- ▶ IMOB: índice do setor imobiliário
- ▶ ICON: índice de consumo
- ▶ IEE: índice de energia
- ▶ INDX: índice da indústria

## Log retorno mensal 2008-2017









# Amostragem aleatória

# Stochastic Dynamic Programming


Um problema de programação dinâmica estocástica pode ser considerado, (Consigli and Dempster, 1998):

1. um problema em múltiplos estágios recursivo;
2. um processo de decisões  $d_t$  em  $t = 1, \dots, T$ ;
3. com restrições conhecidas e parâmetros  $w_t$  aleatórios.

Ao longo de todo o período  $t = 1, \dots, T$ , (Kouwenberg and Zenios, 2008):

1. as decisões em  $d_t$  estão intercaladas pelo que foi observado no instante  $w_{t-1}$  e o que não se conhece sobre  $w_t$
2. A relação entre a decisão tomada  $d_{t-1}$  e o parâmetro de incerteza  $w_{t-1}$  é **antecipativa** (condições de incerteza)
3. enquanto a relação entre  $d_t$  e  $w_{t-1}$  é **adaptativa** (ambiente de aprendizagem)

# Estrutura de decisão



## Estrutura de decisão

$$\begin{aligned} \text{Minimize: } & Z = f(d_t) + E(q(d_t^*, w_t)) \\ \text{Sujeito } & Ad_t = b \\ & W(w_t)d_t^* = h(w_t) - T(w_t)d_t \end{aligned} \tag{3}$$

Otimizar, no instante  $t$ :

- ▶ função  $f(d_t)$  de custo formada pelo estágio antecipativo
- ▶ e o valor esperado da função custo adaptativa  $q(d_t^*, w_t)$ .

## Estrutura de decisão

$$\begin{aligned} \text{Minimize: } & Z = f(d_t) + E(q(d_t^*, w_t)) \\ \text{Sujeito } & Ad_t = b \\ & W(w_t)d_t^* = h(w_t) - T(w_t)d_t \end{aligned} \tag{3}$$

Otimizar, no instante  $t$ :

- ▶ função  $f(d_t)$  de custo formada pelo estágio antecipativo
  - ▶ e o valor esperado da função custo adaptativa  $q(d_t^*, w_t)$ .
1.  $A$ : matriz tecnológica para  $d_t$
  2.  $b$ : vetor de recursos para  $d_t$
  3.  $T(w_t)$ : matriz tecnológica que transforma  $d_t$  em recursos  $d_t^*$
  4.  $h(w_t)$ : de recursos para  $d_t^*$
  5.  $A$ : matriz tecnológica para  $d_t^*$

## Cenário discretizado

Discretizar o parâmetro de incerteza  $w_t$  em **cenários**

$\Omega = \{w_t^1, w_t^2, \dots, w_t^N\}$  (Kouwenberg and Zenios, 2008).

►  $p^{(l)} = \pi(w_t = w_t^{(l)})$

►  $\sum_{l=1}^N p^{(l)} = 1$


$$\text{Minimize: } Z = f(d_t) + \sum_{l=1}^N p^{(l)} q(d_t^{*(l)}, w_t^{(l)}) \quad (4)$$

$$\text{Sujeito } Ad_t = b$$

$$W(w_t^{(l)})d_t^{*(l)} = h(w_t^{(l)}) - T(w_t^{(l)})d_t$$

## Estrutura de decisão

1. O processo de otimização se repete dinamicamente a medida em que se tenha acesso a novas informações sobre  $w_t$ .
2. A decisão  $d_t^*$  no instante  $t$  é a decisão  $d_{t+1}$  do instante  $t + 1$ .





## Função objetivo

A função objetivo pode ser adaptada para:

- ▶ minimizar custo de administração (Kouwenberg and Zenios, 2008)
- ▶ maximizar o valor final da carteira (Johannes et al., 2014)
- ▶ minimizar o risco (Ferstl and Weissensteiner, 2011) e (Quaranta and Zaffaroni, 2008).

# Amostragem aleatória (Intuitivo)

## Value at Risk (VaR)

Definida a carteira ótima:

- ▶ em um dia ruim, quanto eu posso perder?


## Value at Risk (VaR)

Definida a carteira ótima:

- ▶ em um dia ruim, quanto eu posso perder?
- ▶ quantos dias ruins eu suportaria para manter esse portfólio?

# Monte Carlo

## Log retorno mensal 2008-2017



# Monte Carlo

- ▶ descrição: (re)amostragem “paramétrica”
- ▶ vantagens: acessa “todo” espaço
- ▶ desvantagem: conhecimento prévio da distribuição

## Normal Multivariada

$$X \sim N_k(\tilde{\mu}, \Sigma)$$

$$f(X) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\det \Sigma}} \exp \left( -\frac{1}{2} (\tilde{X} - \tilde{\mu}) \Sigma^{-1} (\tilde{X} - \tilde{\mu}) \right)$$


1. modelo
2. parâmetros
3. amostragem



## Code - MC

```
set.seed(1052210218)
library(MASS)
n_mc <- 100000
mc <- mvrnorm(n=n_mc,mu,Sigma)
mc <- matriz_mc %*% w_optm
qlim <- quantile(mc,p=0.05)
```

## Value at Risk (Var)



## Pontos importantes

- ▶ Suposição da distribuição:
- ▶ Estrutura de dependência longitudinal?

# Bootstrap


# Bootstrap

- ▶ descrição: (re)amostragem “não-paramétrica”
- ▶ vantagens: não requer conhecimento sobre a distribuição
- ▶ desvantagem: acessa espaço “realizado”

# Bootstrap

- ▶ descrição: (re)amostragem “não-paramétrica”
- ▶ vantagens: não requer conhecimento sobre a distribuição
- ▶ desvantagem: acessa espaço “realizado”
  
- ▶ Suposição da distribuição: amostragem aleatória nos próprios dados
- ▶ Estrutura de dependência longitudinal: Base dividida em janelas 5 meses

## Value at Risk (Var) - Bootstrap



# Modelos Dinâmicos



## Modelo dinâmico

### Parte não observável - sistema

Sequência  $\theta_t$  com estrutura de dependência de um Processo Markoviano,  $\{\theta_t, t = 1, \dots, n\}$ .

## Modelo dinâmico


### Parte não observável - sistema

Sequência  $\theta_t$  com estrutura de dependência de um Processo Markoviano,  $\{\theta_t, t = 1, \dots, n\}$ .


### Parte observável

Sequência  $y_t$   $\{y_t, t = 1, \dots, n\}$  que é dependente, exclusivamente, de  $\theta_t$ .

## Modelo dinâmico




## Modelo dinâmico



### Equação do Sistema

$$\theta_t \sim \pi(.|\theta_{t-1})$$

## Modelo dinâmico



### Equação do Sistema

$$\theta_t \sim \pi(\cdot | \theta_{t-1})$$

### Equação das Observações

$$y_t \sim \pi(\cdot | \theta_t)$$

## Propriedades

**A.1:**  $\theta_t, t = 1, \dots, n$  é uma sequência de estados de um Processo Markoviano;

$$\pi(\theta_{1:n}) = \pi(\theta_1) \prod_{k=2}^n \pi(\theta_k | \theta_{k-1})$$

## Propriedades

**A.1:**  $\theta_t, t = 1, \dots, n$  é uma sequência de estados de um Processo Markoviano;

$$\pi(\theta_{1:n}) = \pi(\theta_1) \prod_{k=2}^n \pi(\theta_k | \theta_{k-1})$$

**A.2:**  $y_{1:t}$  é um vetor de observações que são condicionalmente independentes dado  $\theta_{1:t}$ , para cada  $t = 1, \dots, n$ .

$$\pi(y_t | \theta_{1:t}, y_{1:t-1}) = \pi(y_t | \theta_t)$$

## Distribuição conjunta

Essas propriedades permitem descrever a **distribuição conjunta** das observações e dos estados como o produto das seguintes **distribuições condicionais**:

$$\pi(y_{1:n}, \theta_{1:n}) = \pi(\theta_0) \prod_{t=1}^n \pi(\theta_t | \theta_{t-1}) \pi(y_t | \theta_t)$$

Interesse:

$$\pi(\theta_{1:n} | y_{1:n}) = \frac{\pi(\theta_{1:n}, y_{1:n})}{\pi(y_{1:n})}$$



# Monte Carlo (formal)

## Definição

**Distribuição alvo :**  $\pi_n(\theta_1, \dots, \theta_n)$  para  $n$  fixo.

## Definição

**Distribuição alvo** :  $\pi_n(\theta_1, \dots, \theta_n)$  para  $n$  fixo.

Gera-se  $N$  amostras independentes da variável aleatória

$$\Theta_{1:n}^i \sim \pi_n(\theta_1, \dots, \theta_n), \quad i = 1, \dots, N.$$

## Definição

**Distribuição alvo** :  $\pi_n(\theta_1, \dots, \theta_n)$  para  $n$  fixo.

Gera-se  $N$  amostras independentes da variável aleatória  $\Theta_{1:n}^i \sim \pi_n(\theta_1, \dots, \theta_n)$ ,  $i = 1, \dots, N$ .

Aproximação e dada por:

$$\hat{\pi}_n(\theta_1, \dots, \theta_n) = \frac{1}{N} \sum_i^N \delta_{\Theta_{1:n}^i}(\theta_{1:n}),$$

sendo  $\delta_{\Theta_{1:n}^i}(\theta_{1:n})$  uma função indicadora de massa no ponto  $\theta_{1:n}$ .

## Definição

Considerar mensurar uma função  $\phi_n$  em  $\pi(\theta_1, \dots, \theta_n)$ :

$$E(\phi_n) = \int \phi_n(\theta_1, \dots, \theta_n) \pi_n(\theta_1, \dots, \theta_n) d\theta_{1:n}$$

## Definição

Considerer mensurar uma função  $\phi_n$  em  $\pi(\theta_1, \dots, \theta_n)$ :

$$E(\phi_n) = \int \phi_n(\theta_1, \dots, \theta_n) \pi_n(\theta_1, \dots, \theta_n) d\theta_{1:n}$$

Pelo método Monte Carlo, **avaliamos**  $\phi_n$  no suporte simulado de  $\pi(\theta_1, \dots, \theta_n)$  por meio das **amostras**:

$$\hat{E}(\phi_n) = \int \phi_n(\theta_1, \dots, \theta_n) \hat{\pi}_n(\theta_1, \dots, \theta_n) d\theta_{1:n}$$

## Definição

Considerer mensurar uma função  $\phi_n$  em  $\pi(\theta_1, \dots, \theta_n)$ :

$$E(\phi_n) = \int \phi_n(\theta_1, \dots, \theta_n) \pi_n(\theta_1, \dots, \theta_n) d\theta_{1:n}$$

Pelo método Monte Carlo, **avaliamos**  $\phi_n$  no suporte simulado de  $\pi(\theta_1, \dots, \theta_n)$  por meio das **amostras**:

$$\hat{E}(\phi_n) = \int \phi_n(\theta_1, \dots, \theta_n) \hat{\pi}_n(\theta_1, \dots, \theta_n) d\theta_{1:n}$$

$$\hat{E}(\phi_n) = \frac{1}{N} \sum_{i=1}^N \phi_n(\Theta_{1:n}^i)$$

## Desvantagens

**Problema 1**: Não é fácil se gerar  $\pi_n(\theta_1, \dots, \theta_n)$ . (Amostragem de Importância)



## Desvantagens

**Problema 1**: Não é fácil se gerar  $\pi_n(\theta_1, \dots, \theta_n)$ . (Amostragem de Importância)

**Problema 2**: Ainda que fosse possível se gerar, a dimensão de  $\pi_n(\theta_1, \dots, \theta_n)$  pode ser muito grande para se obter amostras multivariadas. Problema encontrado no método **MCMC**. (Amostragem de Importância Sequencial)

## Amostragem de importância sequencial

As propriedades Markovianas A.1 e A.2 garantem:

$$\alpha_n(\theta_{1:n}) = \frac{p(y_n|\theta_n)p(\theta_n|\theta_{n-1})}{q_n(\theta_n|\theta_{1:n-1})}$$

## Amostragem de importância sequencial

As propriedades Markovianas A.1 e A.2 garantem:

$$\alpha_n(\theta_{1:n}) = \frac{p(y_n|\theta_n)p(\theta_n|\theta_{n-1})}{q_n(\theta_n|\theta_{1:n-1})}$$

Chamada de **peso de incremento**, a parte responsável pelo processo **sequencial** de estimação.

$$w_n(\theta_{1:n}) = w_{n-1}(\theta_{1:n-1})\alpha_n(\theta_{1:n})$$

## Amostragem de Importância sequencial

Considere o processo sequencial de reponderação do processo de Amostragem sequencial de Importância:

$$w_t \propto \frac{\pi(y_t|\theta_t)\pi(\theta_t|\theta_{t-1})}{g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})} w_{t-1}$$

## Amostragem de Importância sequencial

Considere o processo sequencial de reponderação do processo de Amostragem sequencial de Importância:

$$w_t \propto \frac{\pi(y_t|\theta_t)\pi(\theta_t|\theta_{t-1})}{g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})} w_{t-1}$$

A função  $g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})$  é a responsável por gerar as propostas de partículas, conhecida como **função de transição de importância**.

## Amostragem de Importância sequencial

Considere o processo sequencial de reponderação do processo de Amostragem sequencial de Importância:

$$w_t \propto \frac{\pi(y_t|\theta_t)\pi(\theta_t|\theta_{t-1})}{g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})} w_{t-1}$$

A função  $g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})$  é a responsável por gerar as propostas de partículas, conhecida como **função de transição de importância**.

Os tipos de filtro de partículas são definidos pelo tipo de equação  $g_{t|t-1}(\cdot)$  escolhida.

# Filtro de partículas

# Partículas

## Definição

**Parte** de um todo



# Partículas

## Definição

**Parte** de um todo

1. Parte: Partículas.

# Partículas

## Definição

Parte de um **todo**

1. Parte: Partículas.
2. Todo: Espaço paramétrico.

# Partículas

## Definição

Parte de um todo.

1. Parte: Partículas.
2. Todo: Espaço paramétrico.

## Definição

Partículas são realizações de um experimento cujos valores possíveis estão definidos no espaço paramétrico.

# Filtro de Partículas

# Filtro Bootstrap

## Sistema Dinâmico

Proposto por Gordon et al. (1993).

Equação do sistema

$$\theta_t = f(\theta_{t-1}, w_t),$$

# Sistema Dinâmico

Proposto por Gordon et al. (1993).

Equação do sistema

$$\theta_t = f(\theta_{t-1}, w_t),$$

Equação das observações

$$y_t = h(\theta_t, v_t),$$

Proposto por Gordon et al. (1993).

Equação do sistema

$$\theta_t = f(\theta_{t-1}, w_t),$$

Equação das observações

$$y_t = h(\theta_t, v_t),$$

Considere:

- ▶  $w_t \sim p_1(\cdot)$  e  $v_t \sim p_2(\cdot)$
- ▶  $p(\theta_1 | D_0) = p(\theta_1)$



## Objetivo

Considerare a *posteriori*:

$$p(\theta_t|D_t) = \frac{h(y_t|\theta_t)p(\theta_t|D_{t-1})}{\int h(y_t|\theta_t)p(\theta_t|D_{t-1})d\theta_t}$$

## Objetivo

Considere a *posteriori*:

$$p(\theta_t|D_t) = \frac{h(y_t|\theta_t)p(\theta_t|D_{t-1})}{\int h(y_t|\theta_t)p(\theta_t|D_{t-1})d\theta_t}$$

**Três grandes tarefas:**

3: *Posteriori*

$$\overbrace{p(\theta_t|D_t)}$$

=

2: Atualização

$$\overbrace{\left[ \frac{h(y_t|\theta_t)}{\int h(y_t|\theta_t)p(\theta_t|D_{t-1})d\theta_t} \right]}$$

1: Propagação

$$\overbrace{p(\theta_t|D_{t-1})}$$

## 1: Propagação

Por meio do suporte de  $p(\theta_{t-1}|D_{t-1})$ ,

$$p(\theta_t|D_{t-1}) = \int f(\theta_t|\theta_{t-1})p(\theta_{t-1}|D_{t-1})d\theta_{t-1}$$

## 1: Propagação

Por meio do suporte de  $p(\theta_{t-1}|D_{t-1})$ ,

$$p(\theta_t|D_{t-1}) = \int f(\theta_t|\theta_{t-1})p(\theta_{t-1}|D_{t-1})d\theta_{t-1}$$

e “atravessando” a equação dos estados latente do sistema pelo suporte de  $w_t$ ,

$$p(\theta_t|\theta_{t-1}) = \int f(\theta_t|\theta_{t-1}, w_t)p(w_t|\theta_{t-1})dw_t$$

## 1: Propagação

Por meio do suporte de  $p(\theta_{t-1}|D_{t-1})$ ,

$$p(\theta_t|D_{t-1}) = \int f(\theta_t|\theta_{t-1})p(\theta_{t-1}|D_{t-1})d\theta_{t-1}$$

e “atravessando” a equação dos estados latente do sistema pelo suporte de  $w_t$ ,

$$p(\theta_t|\theta_{t-1}) = \int f(\theta_t|\theta_{t-1}, w_t)p(w_t|\theta_{t-1})dw_t$$

obtém-se de forma determinística,

$$p(\theta_t|D_{t-1}) = \int \int f(\theta_t|\theta_{t-1}, w_t)p(w_t)p(\theta_{t-1}|D_{t-1})dw_t d\theta_{t-1}$$

## 1: Propagação

Com isso, pode-se obter  $p(\theta_t | D_{t-1})$ , faz-se:

## 1: Propagação

Com isso, pode-se obter  $p(\theta_t|D_{t-1})$ , faz-se:

- 1- gerar suporte de  $\theta_{t-1}$  a partir de  $p(\theta_{t-1}|D_{t-1})$ . **Todo suporte da distribuição  $\theta_{t-1}$ .**

# 1: Propagação

Com isso, pode-se obter  $p(\theta_t|D_{t-1})$ , faz-se:

- 1- gerar suporte de  $\theta_{t-1}$  a partir de  $p(\theta_{t-1}|D_{t-1})$ . **Todo suporte da distribuição  $\theta_{t-1}$ .**
- 2- gerar suporte de  $w_t$  a partir de  $p(w_t)$ . **Todo suporte da distribuição  $w_t$ .**



# 1: Propagação

Com isso, pode-se obter  $p(\theta_t|D_{t-1})$ , faz-se:

- 1- gerar suporte de  $\theta_{t-1}$  a partir de  $p(\theta_{t-1}|D_{t-1})$ . **Todo suporte da distribuição**  $\theta_{t-1}$ .
- 2- gerar suporte de  $w_t$  a partir de  $p(w_t)$ . **Todo suporte da distribuição**  $w_t$ .
- 3- Obter de forma determinística, o suporte da distribuição de interesse por meio de  $\{\theta_{t-1}, w_t\}$ , **obtidos pela função**  $h(\cdot)$ .

## 1: Propagação

Com isso, pode-se obter  $p(\theta_t|D_{t-1})$ , faz-se:

- 1- gerar suporte de  $\theta_{t-1}$  a partir de  $p(\theta_{t-1}|D_{t-1})$ . **Todo suporte da distribuição**  $\theta_{t-1}$ .
- 2- gerar suporte de  $w_t$  a partir de  $p(w_t)$ . **Todo suporte da distribuição**  $w_t$ .
- 3- Obter de forma determinística, o suporte da distribuição de interesse por meio de  $\{\theta_{t-1}, w_t\}$ , **obtidos pela função**  $h(\cdot)$ .

A equação de interesse é representada por:

$$p(\theta_t|D_{t-1}) = \int \int \overbrace{h(\theta_t|\theta_{t-1}, w_{t-1})}^3 \overbrace{p(w_{t-1})}^2 \overbrace{p(\theta_{t-1}|D_{t-1})}^1 dw_{t-1} d\theta_{t-1}$$

## 2: Atualização

A distribuição gerada, “atravessa” a equação observável do sistema pelo suporte de  $v_t$ ,

$$p(y_t|\theta_t) = \int h(y_t|\theta_t, v_t)p(v_t)dv_t,$$

## 2: Atualização

A distribuição gerada, “atravessa” a equação observável do sistema pelo suporte de  $v_t$ ,

$$p(y_t|\theta_t) = \int h(y_t|\theta_t, v_t)p(v_t)dv_t,$$

e é avaliada por:

$$\pi_t \propto h(y_t|\theta_t, v_t)$$

.

### 3: Posteriori

Obtém-se a distribuição de  $p(\theta_t|D_t)$  por meio da combinação entre **1:Propagação** e **2:Atualização**.

### 3: Posteriori

Obtém-se a distribuição de  $p(\theta_t|D_t)$  por meio da combinação entre **1:Propagação** e **2:Atualização**.

$$\overbrace{p(\theta_t|D_t)}^{3:Posteriori} = \overbrace{\left[ \frac{h(y_t|\theta_t)}{\int h(y_t|\theta_t)p(\theta_t|D_{t-1})d\theta_t} \right]}^{2:Atualização} \underbrace{p(\theta_t|D_{t-1})}_{1: Propagação}$$

## Algoritmo

**1.1** Para  $t = 1$ : gerar  $N$  amostras  $\{\theta_0^i, i = 1, \dots, N\} \sim p(\theta_0)$ ;

**1.2** Para  $t > 1$ : gerar  $N$  amostras  
 $\{\theta_{t-1}^i, i = 1, \dots, N\} \sim p(\theta_{t-1} | D_{t-1})$

**2** Gerar  $N$  amostra para  $w_t^i \sim p_1(w)$

**3** Obter valores de  $\theta_t^{i*}$ , de forma determinística,  
 $\theta_{t*}^i = f(\theta_{t-1}^i, w_t^i)$

**4** Sendo  $v_t$  uma estatística conhecida, atualiza-se o peso de  $\theta_t^{i*}$  usando:

$$\pi_t^i = \frac{p(y_t | \theta_t^{i*}, v_t)}{\sum_j^N p(y_t | \theta_t^{j*}, v_t)}$$

**5** Reamostrar  $N$  vezes  $\{\theta_t^{i*}, i = 1, \dots, N\}$  com probabilidade igual a  $\pi_t^i$ .

# Stochastic Volatility Models (SVM)



- ▶ inicialmente com distribuição gaussiana (Hull and White, 1987).
- ▶ atualmente distribuições de caudas pesadas e misturas de normais (Virbickaite et al., 2016).

Uma possível formulação para o modelo SVM é:

$$\begin{aligned}y_t &= \exp\left(\frac{x_t}{2}\right) \varepsilon_t \\x_t &= \alpha + \beta x_{t-1} + w_t\end{aligned}\tag{5}$$

## Linearização

Linearização  $r_t = \log(y_t^2)$  (Kim et al., 1998):

$$\begin{aligned} r_t &= x_t + v_t \\ x_t &= \beta x_{t-1} + w_t \end{aligned} \tag{6}$$

Caso  $\varepsilon_t \sim N(0, 1)$  a distribuição exata é  $\log(\chi^2)$ , sendo  $\chi^2$  distribuição Qui-Quadrado. Aproximação com mistura de normais com os seguintes parâmetros:


$$v_t \sim \log(\chi^2) \approx \sum_{i=1}^7 \pi_i f_N(\mu_i, \sigma^2) \tag{7}$$

## Simulação

Considere o modelo SV básico com parâmetros


1.  $\tau^2 = 0.1$
2.  $\beta = -0.2$
3.  $\alpha = 0.5$
4. simulado para um período de  $T = 1000$
5.  $M = 5000$  partículas

## Estados latentes (variâncias)




Volatilidade estimada pelo modelo SV simulado entre  $t \in [100; 200]$ . A região em cinza representa o intervalo de credibilidade ao nível de 95% e em vermelho os valores verdadeiros.

## SVM - parâmetros




Estimativas dinâmicas para o parâmetro  $\tau^2$ .

## SVM - parâmetros



Estimativas dinâmicas para o parâmetro  $\beta$

## SVM - parâmetros



Estimativas dinâmicas para o parâmetro  $\alpha$

## SVM - parâmetros

	$\tau = \sqrt{0.1} = 0.31$				$\beta = -0.2$				$\alpha = 0.5$			
	$\bar{\tau}$	$\tilde{\tau}$	$q_{5\%}$	$q_{95\%}$	$\bar{\beta}$	$\tilde{\beta}$	$q_{5\%}$	$q_{95\%}$	$\bar{\alpha}$	$\tilde{\alpha}$	$q_{5\%}$	$q_{95\%}$
Simulação	0.34	0.24	0.21	0.45	-0.23	-0.23	-0.29	-0.17	0.34	0.34	0.29	0.44

Distribuição a posteriori dos hiperparâmetros nos modelos SV simulado com  $M = 5000$ .



# Aplicação

Aplicação de R\$ 1000 baseado nos dados 2008 – 2017 dos ativos:

- ▶ IFN: índice setor financeiro
- ▶ IMOB: índice do setor imobiliário
- ▶ ICON: índice de consumo
- ▶ IEE: índice de energia
- ▶ INDX: índice da indústria
- ▶ IBOV: índice geral da bolsa de São Paulo
- ▶ LTN: Letra do Tesouro Nacional

Ajustar um modelo SV para cada série individualmente.

1. simulação de 10000 carteiras aleatórias
2. 10000 cenários
3. utilizando os parâmetros estimados para o modelo SV
4. 252 períodos

Alocação no ativo (%)							Valor final da carteira			
ICON	IEE	IFN	IMOB	INDX	IBOV	LTN	$VaR_{99\%}$	$VaR_{95\%}$	$\bar{R}$	$\sigma(W)$
11.21	2.67	11.81	1.27	35.79	9.16	28.09	624.84	711.95	7.50	241.79
34.27	2.89	11.98	16.57	2.97	1.78	29.54	597.63	733.85	8.34	242.06
34.35	0.66	7.85	2.53	0.79	25.12	28.71	633.07	728.82	8.08	249.42
17.78	0.86	10.60	15.77	23.91	5.93	25.14	607.13	711.50	6.27	251.81
20.13	2.77	5.07	13.93	6.28	20.94	30.89	611.37	701.44	7.00	254.07

Informações das 5 melhores carteiras no modelo SV independente. Análise de 10000 carteiras, simuladas em 10000 cenários de 252 períodos.

- ▶ retorno médio esperado de 7.5%
- ▶ *VaR* ao nível 99% de R\$ 624.84
- ▶ *VaR* ao nível 95% de R\$ 711.95
- ▶ pelo menos 25% dos recursos alocados no ativo livre de risco.

# Perguntas?

igor.ferreira.n@gmail.com

lamfo.unb.br

lamfo-unb.github.io

- Consigli, G. & Dempster, M. a. H. (1998). *Annals of Operations Research*, 81(October):131 – 161.
- Doucet, A. & Johansen, A. M. (2008). A tutorial on particle filtering and smoothing:fifteen years later. Technical report (Department of Statistics, University of British Columbia).
- Ferstl, R. & Weissensteiner, A. (2011). Asset-liability management under time-varying investment opportunities. *Journal of Banking and Finance*, 35(1):182–192.
- Gordon, N. J., Salmond, D. J., & Smith, A. F. M. (1993). Novel approach to nonlinear/non-gaussian bayesian state estimation. *IEEE Proceedings F on Radar and Signal Processing*, (140):107–113.
- Hull, J. & White, A. (1987). The Pricing of Options on Assets with Stochastic Volatilities. *The Journal of Finance*.
- Johannes, M., Korteweg, A., & Polson, N. (2014). Sequential learning, predictability, and optimal portfolio returns. *Journal of Finance*, 69(2):611–644.
- Kim, S., Shepherd, N., & Chib, S. (1998). Stochastic Volatility: Likelihood Inference and Comparison with ARCH Models. *Review of Economic Studies*, 65(3):361–393.
- Kouwenberg, R. & Zenios, S. A. (2008). Stochastic Programming Models for Asset Liability Management. In: *Handbook of Asset and Liability Management - Set, volume 1*, pages 253–303. incollection.
- Laloux, L., Cizeau, P., Bouchaud, J. P., & Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7):1467–1470.
- Markowitz, H. M. (1952). Portfolio selection. *The Journal of Finance*.
- Petris, G., Petrone, S., & Campagnoli, P. (2009). *Dynamic Linear Models with R*. Springer.
- Quaranta, A. G. & Zaffaroni, A. (2008). Robust optimization of conditional value at risk and portfolio selection. *Journal of Banking and Finance*, 32(10):2046–2056.
- Virbickaite, A., Lopes, H. F., Ausin, M. C., & Galeano, P. (2016). Particle Learning for Bayesian Non-Parametric Markov Switching Stochastic Volatility Model. *R&R Bayesian Analysis*, 2(1):1–28.