

Antecipação e adaptação: como incorporar o dinamismo do mundo financeiro

Igor Nascimento

Laboratório de Aprendizado de Máquina em Finanças e Organizações - LAMFO

28/02/2018

Sumário

Introdução

Monte Carlo

Bootstrap

Stochastic Dynamic Programming

Modelos Dinâmicos

Monte Carlo

Amostragem de Importância

Amostragem de Importância Sequencial

Reamostragem

Filtro de Partículas

Stochastic Volatility Models

O investidor (banco, pessoa física, fundo de investimento, fundo de pensão) possui um capital e deseja utilizá-lo para atingir um objetivo:

- ▶ Rendimento superior a taxa de captação
- ▶ Segurança financeira
- ▶ Lucro ao investidor
- ▶ Aposentadoria

Alocação de ativos ou portfólio é **escolher** um ou mais ativos.

- ▶ Ações (PETR3, VALE3, IBOVESPA)
- ▶ Títulos de dívida pública (NTN-B, LTN)
- ▶ Empresa de terceiros (Debêntures)
- ▶ Empresas própria (Empresário)

Alocação de ativos ou portfólio é **escolher** um ou mais ativos.

- ▶ Ações (PETR3, VALE3, IBOVESPA)
- ▶ Títulos de dívida pública (NTN-B, LTN)
- ▶ Empresa de terceiros (Debêntures)
- ▶ Empresas própria (Empresário)
- ▶ Outros (criptomoeda, Avestrus Master, Hinode)

Alocação

- ▶ Retorno: qual o valor esperado ao final do investimento
- ▶ Risco: quais são os valores possíveis para o retorno

O trabalho seminal de Markowitz (1952) sobre alocação de portfólio e fronteira eficiente.

Markowitz (1952)

- ▶ ativos:

$$r_1, r_2, \dots, r_N$$

- ▶ retorno:

$$E(r_1) = \mu_1, E(r_2) = \mu_2, \dots, E(r_N) = \mu_N$$

- ▶ variância:

$$V(r_1) = \sigma_1^2, V(r_2) = \sigma_2^2, \dots, V(r_N) = \sigma_N^2$$

- ▶ covariância (correlação):

$$COR(r_i, r_j) = \rho_{ij}$$

Alocação

Determinar a locação, isto é, o percentual p_1, p_2, \dots, p_N que cada ativo representa da carteira:

$$E_{portfolio} = E(\mathbf{P}) = \sum_{i=1}^N p_i \times \mu_i \quad (1)$$


$$V_{portfolio} = V(\mathbf{P}) = \sum_{i=1}^N \sum_{j=1}^N p_i p_j \times \sigma_i \sigma_j \times \rho_{ij} \quad (2)$$

"Optimal weight of each asset, such that the overall portfolio provides the best return for a fixed level of risk, or conversely, the smallest risk for a given overall return?" Laloux et al. (1999)

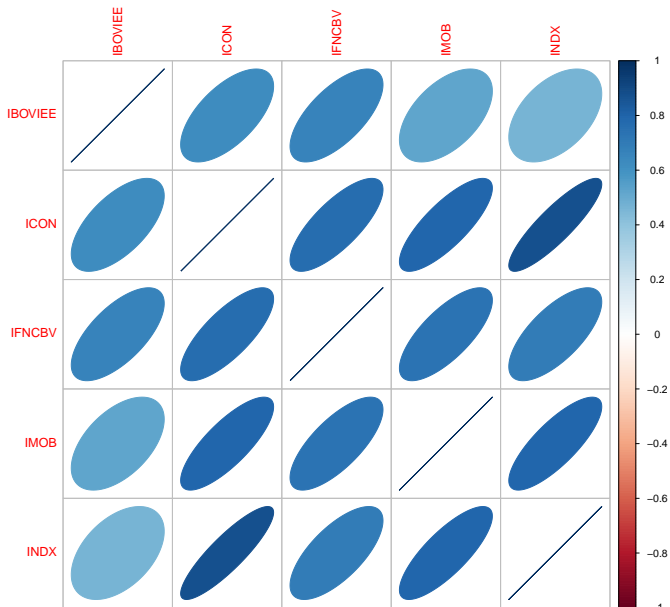
Minicaso

- ▶ IFN: índice setor financeiro
- ▶ IMOB: índice do setor imobiliário
- ▶ ICON: índice de consumo
- ▶ IEE: índice de energia
- ▶ INDX: índice da indústria


Log retorno mensal 2008-2017




Matriz de correlação



Fronteira



Fronteira




em um dia ruim, quanto eu posso perder?

Amostragem aleatória (Intuitivo)

Monte Carlo

Log retorno mensal

2008-2017



Monte Carlo

- ▶ descrição: (re)amostragem “paramétrica”
- ▶ vantagens: acessa “todo” espaço
- ▶ desvantagem: conhecimento prévio da distribuição

Normal Multivariada

$$X \sim N_k(\tilde{\mu}, \Sigma)$$


$$f(X) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(\tilde{X} - \tilde{\mu})\Sigma^{-1}(\tilde{X} - \tilde{\mu})\right)$$

1. modelo
2. parâmetros
3. amostragem

Code - MC

```
set.seed(1052210218)
library(MASS)
n_mc <- 100000
mc <- mvrnorm(n=n_mc,mu,Sigma)
mc <- matriz_mc %*% w_optm
qlim <- quantile(mc,p=0.05)
```

Value at Risk (Var)



Pontos importantes

- ▶ Suposição da distribuição:
- ▶ Estrutura de dependência longitudinal?

Bootstrap


Bootstrap

- ▶ descrição: (re)amostragem “não-paramétrica”
- ▶ vantagens: não requer conhecimento sobre a distribuição
- ▶ desvantagem: acessa espaço “realizado”

Bootstrap

- ▶ descrição: (re)amostragem “não-paramétrica”
- ▶ vantagens: não requer conhecimento sobre a distribuição
- ▶ desvantagem: acessa espaço “realizado”
- ▶ Distribuição: amostragem aleatória nos próprios dados
- ▶ Dependência longitudinal: Base dividida em janelas 5 meses

Value at Risk (Var) - Bootstrap



Stochastic Dynamic Programming

Stochastic Dynamic Programming


Um problema de programação dinâmica estocástica pode ser considerado, (Consigli and Dempster, 1998):

1. um problema em múltiplos estágios recursivo;
2. um processo de decisões d_t em $t = 1, \dots, T$;
3. com restrições conhecidas e parâmetros w_t aleatórios.

Ao longo de todo o período $t = 1, \dots, T$, (Kouwenberg and Zenios, 2008):

1. as decisões em d_t estão intercaladas pelo que foi observado no instante w_{t-1} e o que não se conhece sobre w_t
2. A relação entre a decisão tomada d_{t-1} e o parâmetro de incerteza w_{t-1} é **antecipativa** (condições de incerteza)
3. enquanto a relação entre d_t e w_{t-1} é **adaptativa** (ambiente de aprendizagem)

Estrutura de decisão



Estrutura de decisão

$$\begin{aligned} \text{Minimize: } & Z = f(d_t) + E(q(d_t^*, w_t)) \\ \text{Sujeito } & Ad_t = b \\ & W(w_t)d_t^* = h(w_t) - T(w_t)d_t \end{aligned} \tag{3}$$

Otimizar, no instante t :

- ▶ função $f(d_t)$ de custo formada pelo estágio antecipativo
- ▶ e o valor esperado da função custo adaptativa $q(d_t^*, w_t)$.

Estrutura de decisão

$$\begin{aligned} \text{Minimize: } & Z = f(d_t) + E(q(d_t^*, w_t)) \\ \text{Sujeito } & Ad_t = b \\ & W(w_t)d_t^* = h(w_t) - T(w_t)d_t \end{aligned} \tag{3}$$

Otimizar, no instante t :

- ▶ função $f(d_t)$ de custo formada pelo estágio antecipativo
 - ▶ e o valor esperado da função custo adaptativa $q(d_t^*, w_t)$.
1. A : matriz tecnológica para d_t
 2. b : vetor de recursos para d_t
 3. $T(w_t)$: matriz tecnológica que transforma d_t em recursos d_t^*
 4. $h(w_t)$: de recursos para d_t^*
 5. A : matriz tecnológica para d_t^*

Cenário discretizado

Discretizar o parâmetro de incerteza w_t em **cenários**

$\Omega = \{w_t^1, w_t^2, \dots, w_t^N\}$ (Kouwenberg and Zenios, 2008).

► $p^{(l)} = \pi(w_t = w_t^{(l)})$

► $\sum_{l=1}^N p^{(l)} = 1$


$$\text{Minimize: } Z = f(d_t) + \sum_{l=1}^N p^{(l)} q(d_t^{*(l)}, w_t^{(l)}) \quad (4)$$

$$\text{Sujeito } Ad_t = b$$

$$W(w_t^{(l)})d_t^{*(l)} = h(w_t^{(l)}) - T(w_t^{(l)})d_t$$

Estrutura de decisão

1. O processo de otimização se repete dinamicamente a medida em que se tenha acesso a novas informações sobre w_t .
2. A decisão d_t^* no instante t é a decisão d_{t+1} do instante $t + 1$.



Função objetivo

A função objetivo pode ser adaptada para:

- ▶ minimizar custo de administração (Kouwenberg and Zenios, 2008)
- ▶ maximizar o valor final da carteira (Johannes et al., 2014)
- ▶ minimizar o risco (Ferstl and Weissensteiner, 2011) e (Quaranta and Zaffaroni, 2008).

Modelos Dinâmicos

Modelo dinâmico

Parte não observável - sistema

Sequência θ_t com estrutura de dependência de um Processo Markoviano, $\{\theta_t, t = 1, \dots, T\}$.

Modelo dinâmico


Parte não observável - sistema

Sequência θ_t com estrutura de dependência de um Processo Markoviano, $\{\theta_t, t = 1, \dots, T\}$.


Parte observável

Sequência y_t $\{y_t, t = 1, \dots, T\}$ que é dependente, exclusivamente, de θ_t .

Modelo dinâmico




Modelo dinâmico



Equação do Sistema

$$\theta_t = G_t \theta_{t-1} + w_t$$

Modelo dinâmico



Equação do Sistema

$$\theta_t = G_t \theta_{t-1} + w_t$$

Equação das Observações

$$y_t = F_t \theta_t + v_t$$

Propriedades

A.1: $\theta_t, t = 1, \dots, T$ é uma sequência de estados de um Processo Markoviano;

$$\pi(\theta_{1:T}) = \pi(\theta_1) \prod_{t=2}^T \pi(\theta_t | \theta_{t-1})$$

Propriedades

A.1: $\theta_t, t = 1, \dots, T$ é uma sequência de estados de um Processo Markoviano;

$$\pi(\theta_{1:T}) = \pi(\theta_1) \prod_{t=2}^T \pi(\theta_t | \theta_{t-1})$$

A.2: $y_{1:t}$ é um vetor de observações que são condicionalmente independentes dado $\theta_{1:t}$, para cada $t = 1, \dots, T$.

$$\pi(y_t | \theta_{1:t}, y_{1:t-1}) = \pi(y_t | \theta_t)$$

Distribuição conjunta

Essas propriedades permitem descrever a **distribuição conjunta** das observações e dos estados como o produto das seguintes **distribuições condicionais**:

$$\pi(y_{1:t}, \theta_{1:t}) = \pi(\theta_0) \prod_{t=1}^T \pi(\theta_t | \theta_{t-1}) \pi(y_t | \theta_t)$$

Interesse:

$$\pi(\theta_{1:t} | y_{1:t}) = \frac{\pi(\theta_{1:t}, y_{1:t})}{\pi(y_{1:t})}$$

Filtro de Kalman

- ▶ se v_t e w_t perturbações com distribuição Gaussiana e independentes solução fechada
- ▶ esquema sequencial para o processo de filtragem **Filtro de Kalman** (West and Harrison, 1997)
- ▶ processo dinâmico a cada nova informação
- ▶ maior complexidade requer aproximações **Markov Chain Monte Carlo** (MCMC)
- ▶ dinamicidade das estimações

Monte Carlo (formal)

Definição

Distribuição alvo : $\pi_t(\theta_1, \dots, \theta_t)$ para t fixo.

Definição

Distribuição alvo : $\pi_t(\theta_1, \dots, \theta_t)$ para t fixo.

Gera-se N amostras independentes da variável aleatória
 $\Theta_{1:t}^i \sim \pi_t(\theta_1, \dots, \theta_t)$, $i = 1, \dots, N$.

Definição

Distribuição alvo : $\pi_t(\theta_1, \dots, \theta_t)$ para t fixo.

Gera-se N amostras independentes da variável aleatória $\Theta_{1:t}^i \sim \pi_t(\theta_1, \dots, \theta_t)$, $i = 1, \dots, N$.

Pelo método Monte Carlo, **avaliamos** ϕ_t no suporte simulado de $\pi(\theta_1, \dots, \theta_t)$ por meio das **amostras**:

$$\hat{E}(\phi_t) = \frac{1}{N} \sum_{i=1}^N \phi_t(\Theta_{1:t}^i)$$

Desvantagens

Problema 1: Não é fácil se gerar $\pi_t(\theta_1, \dots, \theta_t)$.

Problema 1: Não é fácil se gerar $\pi_t(\theta_1, \dots, \theta_t)$.

Problema 2: Ainda que fosse possível se gerar, a dimensão de $\pi_t(\theta_1, \dots, \theta_t)$ pode ser muito grande para se obter amostras multivariadas, além de não se ter acesso a todas as informações “agora”.

Amostragem de importância

Problema 1

A amostragem de importância trata o **problema 1**: não se sabe gerar $\pi(\theta_{1:t})$.

Problema 1

A amostragem de importância trata o **problema 1**: não se sabe gerar $\pi(\theta_{1:t})$.

Utiliza-se uma **distribuição de importância** $q(\cdot)$ para obter o mesmo suporte da distribuição $\pi(\cdot)$.

$$E_{\pi}(\phi) = \int \phi(\theta)\pi(\theta)d\theta = \int \frac{\phi(\theta)\pi(\theta)}{q(\theta)}q(\theta)d\theta$$

Problema 1

A amostragem de importância trata o **problema 1**: não se sabe gerar $\pi(\theta_{1:t})$.

Utiliza-se uma **distribuição de importância** $q(\cdot)$ para obter o mesmo suporte da distribuição $\pi(\cdot)$.

$$E_{\pi}(\phi) = \int \phi(\theta) \pi(\theta) d\theta = \int \frac{\phi(\theta) \pi(\theta)}{q(\theta)} q(\theta) d\theta$$

$P(\theta) = \frac{\pi(\theta)}{q(\theta)}$ fornece um ajuste da discrepância de $q(\theta)$ para $\pi(\theta)$

$$\hat{E}(\phi_t) = \frac{1}{N} \sum_{i=1}^N \gamma_n(\Theta_{1:t}^i) \phi_n(\Theta_{1:t}^i).$$

Amostragem de importância sequencial

Problema 2

Amostrar $q_n(\theta_{1:t})$ pode ser **inviável devido a dimensão t** .

Problema 2

Amostrar $q_n(\theta_{1:t})$ pode ser **inviável devido a dimensão t** .

Considere que a distribuição auxiliar escolhida, $q(\cdot)$, possa ser escrita por:

$$q(\theta_{1:t}) = q(\theta_{1:t-1})q(\theta_t|\theta_{t-1})$$

Problema 2

Amostrar $q_n(\theta_{1:t})$ pode ser **inviável devido a dimensão t** .

Considere que a distribuição auxiliar escolhida, $q(\cdot)$, possa ser escrita por:

$$q(\theta_{1:t}) = q(\theta_{1:t-1})q(\theta_t|\theta_{t-1})$$

peso de incremento é a parte **sequencial** de estimação.

$$\Upsilon_t(\theta_{1:t}) = \Upsilon_{t-1}(\theta_{1:t-1})\alpha_n(\theta_{1:t})$$

Monte Carlo Dinâmico:

$$\hat{E}(\phi_t) = \frac{1}{N} \sum_{i=1}^N \textcolor{red}{\Upsilon}_n(\Theta_{1:t}^i) \phi_n(\Theta_{1:t}^i).$$

Amostragem de Importância sequencial

Considere o processo sequencial de reponderação do processo de Amostragem sequencial de Importância:

$$\Upsilon_t \propto \frac{\pi(y_t|\theta_t)\pi(\theta_t|\theta_{t-1})}{g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})} \Upsilon_{t-1}$$

Amostragem de Importância sequencial

Considere o processo sequencial de reponderação do processo de Amostragem sequencial de Importância:

$$\Upsilon_t \propto \frac{\pi(y_t|\theta_t)\pi(\theta_t|\theta_{t-1})}{g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})} \Upsilon_{t-1}$$

A função $g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})$ é a responsável por gerar as propostas de partículas, conhecida como **função de transição de importância** (Johansen and Doucet, 2008).

Amostragem de Importância sequencial


Considere o processo sequencial de reponderação do processo de Amostragem sequencial de Importância:

$$\Upsilon_t \propto \frac{\pi(y_t|\theta_t)\pi(\theta_t|\theta_{t-1})}{g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})} \Upsilon_{t-1}$$

A função $g_{t|t-1}(\theta_t|\theta_{0:t-1}, y_{1:t})$ é a responsável por gerar as propostas de partículas, conhecida como **função de transição de importância** (Johansen and Doucet, 2008).

Os tipos de filtro de partículas são definidos pelo tipo de equação $g_{t|t-1}(\cdot)$ escolhida.

Esquema



Reamostragem

É possível que a distribuição dos pesos Υ_t^i se degenerem. Isso ocorre quando tem-se pesos com valores próximos de 1.

É possível que a distribuição dos pesos Υ_t^i se degenerem. Isso ocorre quando tem-se pesos com valores próximos de 1.

$$\{\theta_t^i, \Upsilon_t^i\}, i = 1, \dots, N$$

É possível que a distribuição dos pesos Υ_t^i se degenerem. Isso ocorre quando tem-se pesos com valores próximos de 1.

$$\{\theta_t^i, \Upsilon_t^i\}, i = 1, \dots, N$$

As partículas θ_t^i são reamostradas com Υ_t^i como peso

É possível que a distribuição dos pesos Υ_t^i se degenerem. Isso ocorre quando tem-se pesos com valores próximos de 1.

$$\{\theta_t^i, \Upsilon_t^i\}, i = 1, \dots, N$$

As partículas θ_t^i são reamostradas com Υ_t^i como peso

As novas partículas tem peso $w_t^i = 1/N$.

Filtro de partículas

Partículas

Definição

Parte de um todo

Partículas

Definição

Parte de um todo

1. Parte: Partículas.

Partículas

Definição

Parte de um **todo**

1. Parte: Partículas.
2. Todo: Espaço paramétrico.

Partículas

Definição

Parte de um todo.

1. Parte: Partículas.
2. Todo: Espaço paramétrico.

Definição

Partículas são realizações de um experimento cujos valores possíveis estão definidos no espaço paramétrico.

Inicialmente proposto por Gordon et al. (1993).

Equação do sistema (Propagação):

$$\theta_t = G\theta_{t-1} + w_t$$

Inicialmente proposto por Gordon et al. (1993).

Equação do sistema (Propagação):

$$\theta_t = G\theta_{t-1} + w_t$$

Equação das observações (atualização):

$$y_t = F\theta_t + v_t$$

Inicialmente proposto por Gordon et al. (1993).

Equação do sistema (Propagação):

$$\theta_t = G\theta_{t-1} + w_t$$

Equação das observações (atualização):

$$y_t = F\theta_t + v_t$$

- $w_t \sim p_1(\cdot)$ e $v_t \sim p_2(\cdot)$

Objetivo

Objetivo é *posteriori* dinâmica em t :

$$p(\theta_t | D_t) = \frac{h(y_t | \theta_t) p(\theta_t | D_{t-1})}{\int h(y_t | \theta_t) p(\theta_t | D_{t-1}) d\theta_t}$$

Objetivo

Objetivo é *posteriori* dinâmica em t :

$$p(\theta_t|D_t) = \frac{h(y_t|\theta_t)p(\theta_t|D_{t-1})}{\int h(y_t|\theta_t)p(\theta_t|D_{t-1})d\theta_t}$$

Três grandes tarefas:

3: *Posteriori*

$$\overbrace{p(\theta_t|D_t)}$$


2: Atualização

$$= \overbrace{\left[\frac{h(y_t|\theta_t)}{\int h(y_t|\theta_t)p(\theta_t|D_{t-1})d\theta_t} \right]}$$

1: Propagação

$$\overbrace{p(\theta_t|D_{t-1})}$$

Esquema



Algoritmo

1.1 Para $t = 1$: gerar N amostras $\{\theta_0^i, i = 1, \dots, N\} \sim p(\theta_0)$;

1.2 Para $t > 1$: gerar N amostras
 $\{\theta_{t-1}^i, i = 1, \dots, N\} \sim p(\theta_{t-1} | D_{t-1})$

2 Gerar N amostra para $w_t^i \sim p_1(w)$

3 Obter valores de θ_t^{i*} , de forma determinística,
 $\theta_{t*}^i = f(\theta_{t-1}^i, w_t^i)$

4 Sendo v_t uma estatística conhecida, atualiza-se o peso de θ_t^{i*} usando:

$$\pi_t^i = \frac{p(y_t | \theta_t^{i*}, v_t)}{\sum_j^N p(y_t | \theta_t^{j*}, v_t)}$$

5 Reamostrar N vezes $\{\theta_t^{i*}, i = 1, \dots, N\}$ com probabilidade igual a π_t^i .

Stochastic Volatility Models (SVM)

- ▶ inicialmente com distribuição gaussiana (Hull and White, 1987).
- ▶ atualmente distribuições de caudas pesadas e misturas de normais (Virbickaite et al., 2016)
- ▶ **modela diretamente a volatilidade**

Uma possível formulação para o modelo SVM é:

$$\begin{aligned}y_t &= \exp\left(\frac{x_t}{2}\right) \varepsilon_t \\x_t &= \alpha + \beta x_{t-1} + w_t\end{aligned}\tag{5}$$

$$w_t \sim N(0, \tau^2)$$

Linearização

Linearização $r_t = \log(y_t^2)$ (Kim et al., 1998):

$$\begin{aligned} r_t &= x_t + v_t \\ x_t &= \alpha + \beta x_{t-1} + w_t \end{aligned} \tag{6}$$

Caso $\varepsilon_t \sim N(0, 1)$ a distribuição exata é $v_t \sim \log(\chi^2)$, sendo χ^2 distribuição Qui-Quadrado. Aproximação com mistura de normais com os seguintes parâmetros:

$$v_t \sim \log(\chi^2) \approx \sum_{i=1}^7 \pi_i f_N(\mu_i, \sigma^2) \tag{7}$$

Simulação


Considere o modelo SV básico com parâmetros

1. $\tau^2 = 0.1$
2. $\beta = -0.2$
3. $\alpha = 0.5$
4. simulado para um período de $T = 1000$
5. $M = 5000$ partículas

$$\begin{aligned}y_t &= \exp\left(\frac{x_t}{2}\right) \varepsilon_t \\x_t &= \alpha + \beta x_{t-1} + w_t\end{aligned}\tag{8}$$


$$w_t \sim N(0, \tau^2)$$

Estados latentes (variâncias)




Volatilidade estimada pelo modelo SV simulado entre $t \in [100; 200]$. A região em cinza representa o intervalo de credibilidade ao nível de 95% e em vermelho os valores verdadeiros.

SV - parâmetros




Estimativas dinâmicas para o parâmetro τ^2 .

SV - parâmetros



Estimativas dinâmicas para o parâmetro β

SVM - parâmetros



Estimativas dinâmicas para o parâmetro α

Aplicação

Aplicação de R\$ 1000 baseado nos dados 2008 – 2017 dos ativos:

- ▶ IFN: índice setor financeiro
- ▶ IMOB: índice do setor imobiliário
- ▶ ICON: índice de consumo
- ▶ IEE: índice de energia
- ▶ INDX: índice da indústria
- ▶ IBOV: índice geral da bolsa de São Paulo
- ▶ LTN: Letra do Tesouro Nacional

Modelo SV para cada série individualmente.

1. utilizando os parâmetros estimados para o modelo SV

1. utilizando os parâmetros estimados para o modelo SV
2. simulação de 10000 carteiras aleatórias

1. utilizando os parâmetros estimados para o modelo SV
2. simulação de 10000 carteiras aleatórias
3. cada carteira avaliada em 10000 cenários

1. utilizando os parâmetros estimados para o modelo SV
2. simulação de 10000 carteiras aleatórias
3. cada carteira avaliada em 10000 cenários
4. 252 períodos

Alocação no ativo (%)							Valor final da carteira			
ICON	IEE	IFN	IMOB	INDX	IBOV	LTN	$VaR_{99\%}$	$VaR_{95\%}$	\bar{R}	$\sigma(W)$
11.21	2.67	11.81	1.27	35.79	9.16	28.09	624.84	711.95	7.50	241.79
34.27	2.89	11.98	16.57	2.97	1.78	29.54	597.63	733.85	8.34	242.06
34.35	0.66	7.85	2.53	0.79	25.12	28.71	633.07	728.82	8.08	249.42
17.78	0.86	10.60	15.77	23.91	5.93	25.14	607.13	711.50	6.27	251.81
20.13	2.77	5.07	13.93	6.28	20.94	30.89	611.37	701.44	7.00	254.07

Informações das 5 melhores carteiras no modelo SV independente. Análise de 10000 carteiras, simuladas em 10000 cenários de 252 períodos.

- ▶ retorno médio esperado de 7.5%
- ▶ VaR ao nível 99% de R\$ 624.84
- ▶ VaR ao nível 95% de R\$ 711.95
- ▶ pelo menos 25% dos recursos alocados no ativo livre de risco.

Os parâmetros do modelo são **atualizados dinamicamente** a cada nova informação w_t dando suporte para o processo **decisório dinâmico**.

Perguntas?

igor.ferreira.n@gmail.com

lamfo.unb.br

lamfo-unb.github.io

- Consigli, G. & Dempster, M. a. H. (1998). Dynamic stochastic programming for asset-liability management. *Annals of Operations Research*, 81(October):131 – 161.
- Ferstl, R. & Weissensteiner, A. (2011). Asset-liability management under time-varying investment opportunities. *Journal of Banking and Finance*, 35(1):182–192.
- Gordon, N. J., Salmond, D. J., & Smith, A. F. M. (1993). Novel approach to nonlinear/non-gaussian bayesian state estimation. *IEEE Proceedings F on Radar and Signal Processing*, (140):107–113.
- Hull, J. & White, A. (1987). The Pricing of Options on Assets with Stochastic Volatilities. *The Journal of Finance*.
- Johannes, M., Korteweg, A., & Polson, N. (2014). Sequential learning, predictability, and optimal portfolio returns. *Journal of Finance*, 69(2):611–644.
- Johansen, A. M. & Doucet, A. (2008). A note on auxiliary particle filters. *Statistics and Probability Letters*, 78(12):1498–1504.
- Kim, S., Shepherd, N., & Chib, S. (1998). Stochastic Volatility: Likelihood Inference and Comparison with ARCH Models. *Review of Economic Studies*, 65(3):361–393.
- Kouwenberg, R. & Zenios, S. A. (2008). Stochastic Programming Models for Asset Liability Management. In: *Handbook of Asset and Liability Management - Set*, volume 1, pages 253–303. in collection.
- Laloux, L., Cizeau, P., Bouchaud, J. P., & Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7):1467–1470.
- Markowitz, H. M. (1952). Portfolio selection. *The Journal of Finance*.
- Quaranta, A. G. & Zaffaroni, A. (2008). Robust optimization of conditional value at risk and portfolio selection. *Journal of Banking and Finance*, 32(10):2046–2056.
- Virbickaite, A., Lopes, H. F., Ausín, M. C., & Galeano, P. (2016). Particle Learning for Bayesian Non-Parametric Markov Switching Stochastic Volatility Model. *R&R Bayesian Analysis*, 2(1):1–28.
- West, M. & Harrison, J. (1997). *Bayesian Forecast and Dynamic Models*. Springer-Verlag.